Documentação técnica — Pipeline Vendas de Caixa

19 de Outubro de 2026 · Engenheira de Dados - Stephanni Ferrarezi

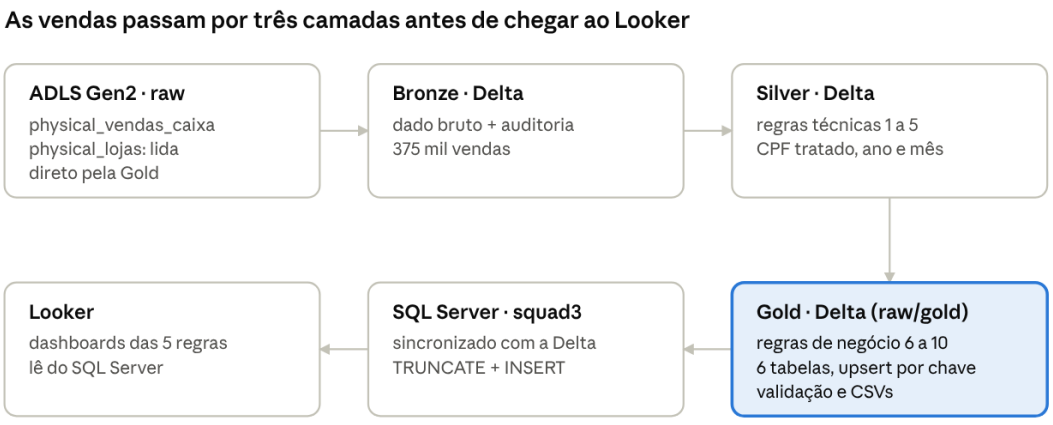
Pipeline em Databricks que lê as vendas de caixa das lojas físicas no Azure Data Lake, trata em camadas Bronze, Silver e Gold, e publica 6 tabelas de KPIs no Delta e no SQL Server para o Looker. Receita e transações da Gold batem com a Silver: R$ 137.214.981,41 em 375.000 vendas.

Visão geral

O pipeline transforma a tabela `physical_vendas_caixa` em indicadores de negócio para as 29 lojas físicas, de jan/2024 a ago/2026. As regras vêm da planilha `regras.xlsx` do tech lead: regras técnicas (1 a 5) na Silver e regras de negócio (6 a 10) na Gold.

Item	Valor
Fonte	`physical_vendas_caixa` (375.000 linhas) e `physical_lojas` (29 lojas), no container `raw` do ADLS Gen2
Colunas de origem	id_transacao, id_loja, id_caixa, id_operador, dt_venda, valor_total_venda, tipo_pagamento, cpf_cliente
Plataforma	Databricks (serverless ou cluster), PySpark, Delta Lake
Destinos	Delta em `raw/gold/` e SQL Server, schema `squad3`
Consumo	Looker, lendo do SQL Server
Autenticação	Service principal OAuth, credenciais no `.env`
Notebook da Gold	`gold_physical_vendas_caixa.py`

Arquitetura



A Gold só lê da Silver; a única exceção é a `physical_lojas`, que não está na Bronze e é lida direto do container raw. Os três notebooks rodam no mesmo compute e usam o mesmo `.env`.

Configuração e execução

Os três notebooks rodam em ordem, Bronze → Silver → Gold, no mesmo compute e com o mesmo `.env`. A Gold procura o `.env` na pasta do notebook e em até três pastas acima; se ele estiver em outro lugar, defina `os.environ["ENV_PATH"]` antes da configuração.

Variável	Obrigatória	Uso
`ADLS_CLIENT_ID`, `ADLS_TENANT_ID`, `ADLS_CLIENT_SECRET`	sim	Service principal do ADLS
`STORAGE_ACCOUNT_NAME`	sim	Conta do Data Lake
`ADLS_CONTAINER`	não (padrão `raw`)	Container de origem e das camadas
`ADLS_SILVER_CONTAINER`, `ADLS_GOLD_CONTAINER`	não	Containers próprios por camada
`SILVER_TABLE_PATH`	não (padrão `silver/physical_vendas_caixa`)	Caminho da Silver
`LOJAS_REL`	não	Caminho da `physical_lojas`; sem ele, o notebook procura no container
`SQL_HOST`, `SQL_DATABASE`, `SQL_USERNAME`, `SQL_PASSWORD`	sim	SQL Server (também aceita o prefixo `SQLSERVER_`)
`SQL_SCHEMA`	não (padrão `squad3`)	Schema de destino
`FATOR_SOBRECARGA`	não (padrão 3)	Limite da regra 9
`GRAVAR_SQLSERVER`, `EXPORTAR_CSV`	não (padrão `true`)	Liga ou desliga a carga no SQL Server e os CSVs
`CSV_DIR`	não (padrão `/Volumes/workspace/default/exportacoes`)	Destino dos CSVs

Para rodar a Gold:

1. Confirme que a Silver foi gravada (a Gold falha com `Silver não encontrada` se não achar).
2. Rode todas as células com **Run all**. A primeira instala `python-dotenv`, `azure-storage-file-datalake` e `azure-identity`.
3. Confira a seção 5 (validação) e baixe os CSVs em Catalog → workspace → default → Volumes → exportacoes.

Nunca compartilhe os valores do `.env`. As credenciais que circularam em chat durante o projeto precisam ser trocadas (ver Pendências).

Regras e tabelas Gold

Cada regra de negócio virou uma tabela, e o grão de cada uma é a chave do upsert. Todas ganham `gold_processed_at`.

Regra	Tabela	Chave	Partição	Linhas (23/10)	Colunas principais
6 — Receita por loja por mês, com MoM	`gold_receita_loja_mes`	id_loja, ano, mes	ano	928	receita_total, qtd_transacoes, receita_mes_anterior, variacao_mom_valor, variacao_mom_pct
7 — Ticket médio por loja e pagamento, anual	`gold_ticket_medio_loja_pagamento_ano`	id_loja, ano, tipo_pagamento	ano	261	receita_total, qtd_transacoes, ticket_medio
8 — % de vendas com e sem CPF por loja por mês	`gold_cpf_identificado_loja_mes`	id_loja, ano, mes	ano	928	qtd_com_cpf, qtd_sem_cpf, pct_com_cpf, pct_sem_cpf, receita_com_cpf, receita_sem_cpf, variacao_pct_com_cpf_pp
9 — Transações por caixa por dia	`gold_transacoes_caixa_dia`	data_venda, id_loja, id_caixa	ano, mes	123.631	qtd_transacoes, media_caixa_dia_loja_mes, razao_vs_media, e_sobrecarregado, e_feriado, tipo_dia
10 — Flag de feriado	`gold_vendas_dia_feriado`	data_venda	ano	974	receita_total, qtd_transacoes,

Regra	Tabela	Chave	Partição	Linhas (23/10)	Colunas principais
nacional					ticket_medio, e_feriado, nome_feriado, e_ponto_facultativo, dia_semana, tipo_dia
Apoio — cadastro de lojas	`gold_dim_lojas`	id_loja	—	29	nome_loja, cidade_loja, estado_loja, peso_vendas

Decisões de cálculo:

- **MoM (regras 6 e 8):** compara com o mês anterior do calendário. Se a loja não vendeu nele, a variação fica nula em vez de comparar com um mês distante.
- **Regra 8:** a variação é em pontos percentuais, porque o indicador já é uma porcentagem. CPF identificado = 11 dígitos depois de tirar a pontuação.
- **Regra 9:** a referência é a média de transações por caixa/dia da mesma loja no mesmo mês; sobrecarregado = 3× essa média ou mais.
- **Regra 10:** feriados calculados no código, inclusive os móveis (Páscoa pelo algoritmo de Meeus) e o 20 de novembro a partir de 2024. Carnaval e Corpus Christi entram como `e_ponto_facultativo`. A coluna é `e_feriado`, sem acento, para não quebrar o SQL Server e o Looker.
- **Ticket médio:** sempre receita ÷ transações. No Looker, recalcule a partir das somas (`sum(receita_total) / sum(qtd_transacoes)`); nunca some ou tire média de colunas que já são razões.
- **Checagem defensiva:** antes de agregar, a Gold confere as regras 2, 3 e 4. Uma linha que viole alguma fica fora da Gold, e o log mostra o motivo, a quantidade e o valor.

Carga

A função `publicar()` grava cada tabela primeiro no Delta e depois deixa o SQL Server igual ao Delta. O resultado final é o mesmo de um MERGE, mas no serverless o comando MERGE literal não está disponível.

Situação	Delta (`raw/gold/<tabela>`)	SQL Server (`squad3.<tabela>`)
Tabela não existe	Cria, particionada	Cria
Esquema mudou	Reescreve com `overwriteSchema`	Recria
Cluster clássico	`MERGE INTO` pela chave	TRUNCATE + INSERT a partir do Delta

Situação	Delta (`raw/gold/<tabela>`)	SQL Server (`squad3.<tabela>`)
Serverless	Upsert por chave: mantém as linhas cuja chave não veio no lote e grava o lote	TRUNCATE + INSERT a partir do Delta

Por que não é MERGE literal no serverless:

- **Credenciais do ADLS:** o serverless não aceita registrá-las na sessão (`spark.conf.set` → `CONFIG_NOT_AVAILABLE`). Elas vão como options em cada leitura e escrita, como na Silver, mas um `MERGE INTO` em SQL não recebe options.
- **API `DeltaTable.merge`:** falha no Spark Connect (`UnknownException`).
- **MERGE em T-SQL:** o serverless bloqueia o conector `jdbc` genérico e comandos SQL soltos; só o conector `sqlserver`, que lê e grava tabelas, é permitido.

Como as tabelas são recalculadas inteiras a cada execução, o estado final é o mesmo. O MERGE literal faria diferença numa carga incremental ou com cargas simultâneas. Para tê-lo, rode a Gold num cluster ou crie uma external location do Unity Catalog para o storage.

Validação e exportação

A seção 5 do notebook confere a Gold gravada contra a Silver em toda execução. Na execução de 23/10/2026, todas as conferências deram OK.

Conferência	Esperado	Resultado em 23/10
Receita das regras 6, 7, 9 e 10	= receita da Silver	R$ 137.214.981,41 nas quatro
Transações da regra 8	= transações da Silver	375.000
Linhas no Delta × SQL Server	iguais	iguais nas 6 tabelas
Linhas excluídas (regras 2, 3 e 4)	0	0
Caixa-dias sobrecarregados	informativo	271, com os 20 maiores exibidos

A seção 6 exporta um CSV por tabela para o Volume `workspace.default.exportacoes`, com separador `;` e vírgula decimal para abrir direto no Excel em português. O arquivo é gravado primeiro em `/tmp` e depois copiado, porque o Volume não aceita escrita parcial.

Problemas encontrados

Quase todos os erros vieram do compute serverless, que tem regras de acesso diferentes das de um cluster. Ficam registrados na ordem em que apareceram, com a solução que ficou no notebook.

Erro	Causa	Solução
`PATH_NOT_FOUND` na leitura da Silver	Silver ainda não gravada no caminho esperado	Rodar as camadas em ordem; caminho configurável por `SILVER_TABLE_PATH`
`ModuleNotFoundError: openpyxl` e `OSError` ao gravar Excel no Volume	Pacote ausente; Volume não aceita a escrita do Excel	Exportação trocada por CSV, gravado em `/tmp` e copiado para o Volume
`NameError: GOLD_BASE`	Sessão reiniciada ao instalar pacote, variáveis perdidas	Rodar a configuração de novo após qualquer `%pip`
`KeyError: STORAGE_ACCOUNT_NAME`	`.env` não encontrado pela Gold	Busca do `.env` na pasta do notebook e acima, ou `ENV_PATH`
`CONFIG_NOT_AVAILABLE` e `AZURE_INVALID_CREDENTIALS_CONFIGURATION`	Serverless não aceita credenciais em `spark.conf`	Credenciais como options em cada leitura e escrita, igual à Silver
`PATH_NOT_FOUND` na `physical_lojas`	Tabela não fica em `raw/physical_lojas`	Busca pelo nome no container via SDK do Azure, com detecção de formato
`UNRESOLVED_COLUMN: data_venda`	A Silver usa `dt_venda`	Gold deriva `data_venda`, `ano`, `mes` e `cliente_identificado` quando faltam
`UNSUPPORTED_DATA_SOURCE_WRITE` (jdbc)	Serverless só aceita o conector `sqlserver`	Escrita pelo conector `sqlserver`
Kernel travado (`pymssql`)	Conexão direta ao Azure SQL não respondeu no serverless	`pymssql` removido; SQL Server sincronizado com o Delta
`UnknownException` no `DeltaTable.merge`	API não suportada no Spark Connect	`MERGE INTO` no cluster e upsert por chave no serverless

Resultados

A rede está estável e o que move os números é a sazonalidade, não a loja nem a forma de pagamento. Números da execução de 23/10/2026, jan/2024 a ago/2026.

Regra	Achado
6 — Receita	Jan a ago: −0,8% em 2025 e +0,2% em 2026. Dezembro vende o dobro de fevereiro (R$ 6,9 mi × R$ 2,9 mi). As 10 maiores lojas fazem 53% da receita; Duque de Caxias lidera com R$ 8,48 mi.
6 — Tendência por loja	Ano contra ano, Riograndina caiu em 7 dos 8 meses de 2026; Araújos e Monte Azul Paulista cresceram em 6 de 8.
7 — Ticket	R$ 365,91 na rede, de R$ 359,60 a R$ 371,95 por loja. Cartão, Dinheiro e Pix têm o mesmo ticket e mix de 60/20/20 nos três anos. Cidade maior não tem ticket maior.
8 — CPF	44,5% das vendas com CPF, sem variação em 32 meses. São Bernardo do Campo tem 57,1%. Ticket com e sem CPF é igual.
9 — Caixas	271 caixa-dias sobrecarregados (0,22%), quase todos em lojas pequenas, onde a média é de cerca de 2 vendas por caixa ao dia.
10 — Feriados	Feriado oficial vende 97 (100 = dia normal do mesmo mês). Domingo vende 115 e sábado 87.

A apresentação do dashboard está nos slides 77 a 84 do modelo da turma (`apresentacao_mercadata_estagio_turma_2_vendas_caixa.pptx`).

Pendências e próximos passos

- ☐ Trocar o client secret do service principal e a senha do usuário do SQL Server, que circularam em chat
- ☐ Validar com o tech lead a média de referência da regra 9 e somar um mínimo absoluto de vendas à razão de 3×
- ☐ Decidir se o MERGE literal é exigido: rodar a Gold num cluster ou criar uma external location no Unity Catalog
- ☐ Corrigir na origem o “nan” no nome de 11 lojas (bairro nulo) e confirmar a ausência do id_loja 14
- ☐ Definir na Silver o tratamento de pagamento vazio, que hoje vira “Não informado” e viola a regra 4
- ☐ Aplicar hash no CPF antes de expor a base (LGPD)
- ☐ Confirmar se a base é simulada: mix exato de pagamento, ticket uniforme e lojas abertas no Natal
- ☐ Orquestrar Bronze → Silver → Gold com Databricks Jobs e montar os dashboards no Looker